

Nama : Marchel Adias Pradana

NPM : 21081010084

Kelas : Riset Informatika C081

Resume Jurnal

Judul	:	Dynamic Structure Learning Through Graph Neural Network For Forecasting Soil Moisture In Precision Agriculture
Jenis Penelitian	:	Penelitian Eksperimental karena penelitian tersebut melakukan percobaan untuk mengembangkan model Graph Neural Network (GNN) yang digunakan untuk memprediksi kelembaban tanah. Model ini diuji dengan data nyata dari pertanian presisi. Penelitian ini bertujuan untuk mengevaluasi seberapa efektif metode baru ini dalam meningkatkan prediksi kelembaban tanah, yang merupakan faktor penting dalam mengelola irigasi dan optimasi pertanian.
Penulis	:	Anoushka Vyas ¹ , Sambaran Bandyopadhyay ²
Publish	:	Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence AI for Good. Pages 5185-5191. https://www.ijcai.org/proceedings/2022/720
Latar Belakang	:	Kelembaban tanah adalah komponen penting dalam pertanian presisi karena berpengaruh langsung pada pertumbuhan dan kualitas tanaman. Peramalan kelembaban tanah yang akurat sangat penting untuk penjadwalan irigasi dan optimalisasi penggunaan air. Pendekatan tradisional seringkali kurang mampu menangkap korelasi spasial dan temporal yang ada pada kelembaban tanah.
Tujuan	:	Penelitian ini bertujuan untuk mengembangkan model Dynamic Graph Learning and Refinement (DGLR) yang menggunakan Graph Neural Networks (GNN) untuk memprediksi kelembaban

		tanah secara lebih akurat dengan menangkap korelasi spasial dan temporal di berbagai lokasi pertanian.
Metodologi	:	<ol style="list-style-type: none"> 1. Dynamic Graph Construction: Model awal dibentuk dengan graf yang merepresentasikan lokasi geografis dan atributnya, seperti suhu, kelembaban relatif, dan NDVI (Normalized Difference Vegetation Index). Node-node dalam graf dihubungkan berdasarkan jarak fisik antar lokasi dengan penambahan self-loop untuk setiap node. 2. Graph Neural Network (GNN): Model GNN digunakan untuk mengupdate embedding setiap node berdasarkan graf yang dinamis. Setiap node memperoleh fitur yang diperbarui melalui mekanisme atensi, di mana bobot hubungan antar node dihitung dan digunakan untuk memperbarui fitur tersebut. 3. Graph Structure Refinement and Regularization: Struktur graf diperbarui secara dinamis selama pelatihan menggunakan regularisasi berbasis kesamaan fitur dan target, serta jarak geografis. Regularisasi ini memastikan bahwa node-node dengan fitur atau target yang serupa cenderung terhubung lebih erat dalam graf. 4. Joint Optimization and Training: Model dilatih secara end-to-end menggunakan fungsi loss yang menggabungkan berbagai komponen, termasuk loss untuk prediksi kelembaban tanah, closeness graf, smoothness fitur, dan smoothness target.
Dataset	:	<p>https://github.com/AnoushkaVyas/DGLR</p> <p>Dataset menggunakan metode semi-supervised learning untuk melatih prediksi kelembaban tanah dari:</p> <ol style="list-style-type: none"> 1. Dataset Kelembaban Tanah dari dua wilayah: Spanyol dan Amerika Serikat. 2. Dataset Spanyol mencakup fitur seperti NDVI, koefisien backscatter dari Sentinel 1 (VV/Vertical-Vertical dan VH/Vertical-Horizontal) yang diambil oleh

		<p>satelit, dan data cuaca seperti suhu rata-rata, kelembaban relatif rata-rata, dan total curah hujan.</p> <p>3. Dataset Amerika Serikat mencakup data seperti suhu tanah dan kelembaban tanah dari jaringan SCAN.</p> <p>Penggunaan metode semi-supervised memungkinkan model untuk memanfaatkan baik data berlabel maupun tidak berlabel. Dengan demikian, model dapat menangani data yang hilang dengan lebih baik dan tetap memberikan prediksi yang akurat meskipun data kelembaban tanah tidak tersedia secara lengkap. Hal ini memberikan ketahanan dan efisiensi dalam penggunaan data, menjadikan model DGLR lebih adaptif terhadap kondisi dunia nyata.</p>
Hasil	:	<p>Model DGLR menunjukkan kinerja yang lebih baik dibandingkan baseline lainnya, terutama dalam hal menangani data yang hilang dan sensitivitas terhadap konstruksi graf awal. Model ini secara signifikan lebih baik dalam memprediksi kelembaban tanah dengan error lebih rendah dan korelasi lebih tinggi.</p>
Kesimpulan	:	<p>Penelitian ini berhasil menunjukkan bahwa model GNN yang dinamis dapat secara efektif memprediksi kelembaban tanah dengan akurasi yang tinggi, bahkan dalam kondisi di mana data yang hilang cukup banyak. DGLR menawarkan solusi yang lebih robust dan adaptif dibandingkan pendekatan lain yang ada.</p> <p>Jurnal ini sangat relevan dengan mata kuliah Pengenalan Pola karena mengaplikasikan konsep-konsep pengenalan pola menggunakan teknologi modern seperti GNN dan DGLR untuk memecahkan masalah nyata dalam pertanian presisi. Ini menunjukkan bagaimana teknik-teknik yang dipelajari dalam pengenalan pola dapat diterapkan untuk membuat prediksi yang lebih baik dan mengambil keputusan yang lebih informatif berdasarkan pola yang diidentifikasi dalam data.</p>
Kelebihan	:	<p>1. Dapat menangani data yang hilang dengan baik.</p>

		<ol style="list-style-type: none"> 2. Mampu memperbarui struktur graf secara dinamis selama pelatihan. 3. Performa lebih baik dibandingkan metode lain dalam memprediksi kelembaban tanah.
Kekurangan	:	<ol style="list-style-type: none"> 1. Komputasi yang kompleks dan memerlukan waktu pelatihan yang lama. 2. Bergantung pada inisialisasi graf awal yang dapat mempengaruhi hasil akhir jika tidak diperbarui dengan baik.